

Predição da irradiação solar por meio de séries temporais

Silva, Matheus Henrique da *

* Universidade Tecnológica Federal do Paraná, PR, (e-mail: matheussilva.2019@alunos.utfpr.edu.br).

Abstract: The work analyzes historical data of solar irradiation in the region of Cornélio Procópio, Paraná, and applies methods of artificial neural networks for short-term prediction in time series. With data obtained from public meteorological stations between 2010 and 2021 and topologies of neural networks of the type Multilayer Perceptron (MLP): time delay neural network (TDNN) and nonlinear auto-regressive with exogenous inputs (NARX), referred to as TDNNm. The TDNNm proved to be more accurate and robust than the TDNN, with a lower average relative error and variance, in addition to fewer epochs needed for training, being able to capture the daily variations of solar irradiation with high similarity to the real values.

Resumo: O trabalho analisa dados históricos de irradiação solar na região de Cornélio Procópio, Paraná, e aplica métodos de redes neurais artificiais para previsão de curto prazo em séries temporais. Com dados obtidos de estações meteorológicas públicas entre 2010 e 2021 e topologias de redes neurais do tipo Perceptron Multi Camadas (MLP): time delay neural network (TDNN) e nonlinear auto-regressive with exogenous inputs (NARX), referida como TDNNm. A TDNNm mostrou-se mais precisa e robusta do que a TDNN, com menor erro relativo médio e variância, além de menos épocas necessárias para o treinamento, sendo capaz de captar as variações diárias da irradiação solar com alta semelhança aos valores reais.

Keywords: Learning; Artificial; Neuron; Neural Network; Time Serie.

Palavras-chaves: Aprendizado; Artificial; Neurônio; Rede Neural; Série Temporal.

1. INTRODUÇÃO

A irradiação solar se destaca como o principal parâmetro utilizado no projeto de implementação e eficiência de sistemas de energia elétrica fotovoltaica (Mehdizadeh et al., 2016). O século 21, até o presente momento, é marcado por uma crescente conscientização sobre os impactos do uso de combustíveis fósseis nas mudanças climáticas, nesse cenário, crescem os investimentos em pesquisa e desenvolvimento focados na realização de uma transição energética para métodos de geração via recursos renováveis, como o Sol (Frei and Kim, 2019).

Dada a forte perspectiva futura de implementação de sistemas de energia fotovoltaica, destacado pelo contínuo aumento da capacidade produtiva com recorde de 266 GW em conjunto com energia eólica, detendo 72% desses acréscimos, em 2022 (Institute, 2023), a previsão de valores futuros da irradiação solar auxilia na gestão e estratégia energética de cidades e indústrias, permitindo ajustes de consumo de outras fontes de acordo com as condições climáticas previstas, tornando o sistema mais estável e confiável (Wu and Chan, 2013).

Portanto, dada a importância econômica da irradiação solar e a gestão energética, este trabalho propõe a análise de dados históricos provenientes de estações meteorológicas públicas em torno da região de Cornélio Procópio, Paraná, de forte potencial entre 4 e 5 kWh/m^2 e altos valores médios mensais, especialmente nos meses de verão (Barbi-

eri et al., 2017). Na sequência, a aplicação de métodos de redes neurais artificiais de previsão de curto prazo em séries temporais, do tipo rede neural *Perceptron Multi Camadas* (MLP), com topologia *time delay neural network* (TDNN) e algoritmo de aprendizagem *backpropagation* com regra Delta generalizada e fator de *momentum* e rede neural MLP, com topologia *Nonlinear Auto-Regressive with exogenous inputs* (NARX), a qual será referida como TDNNm devido ao fato de possuir uma memória dos dados anteriores, (Silva et al., 2010). A comparação entre as duas topologias será realizada para determinar a rede neural mais precisa e robusta para as variações da irradiação solar ao longo dos dias e semanas.

2. REFERENCIAL TEÓRICO

2.1 Irradiação solar

A radiação solar é a energia emitida pelo Sol e transmitida pelo espaço em ondas eletromagnéticas e ao adentrar na na superfície do planeta Terra torna-se irradiação solar. Sua quantificação é fundamental para o desenvolvimento de diversos projetos desde o agronegócio à indústria, e uma das formas é através da radiação solar global (GSI), do inglês *Global Solar Irradiance*, sendo a densidade de fluxo radiante incidente em uma unidade de área em superfície terrestre (Ortiz, 2014).

2.2 Redes Neurais Artificiais

Primeiramente, o neurônio artificial é um elemento computacional utilizado em estruturas de redes neurais artificiais (RNA). Em 1943, os pesquisadores McCulloch e Pitts, inspirados nos neurônios biológicos com características como paralelismo e alta conectividade, propuseram uma estrutura semelhante em âmbito computacional, mantendo a não-linearidade, o fornecimento de saídas tipicamente contínuas e a capacidade de realizar funções simples (Silva et al., 2010).

As redes neurais artificiais são capazes de aprender por meio de treinamentos, nos quais uma série de dados são fornecidos às entradas, sendo esses rotulados ou não, e as interações nas camadas internas da rede por meio dos pesos sinápticos, limiar de ativação e função de ativação, permitem a rede se adaptar por meio de experiência com esses dados. Essa adaptação ocorre, principalmente, por meio da alteração dos pesos sinápticos para melhor entendimento do comportamento das amostras do treinamento sendo que alguns tipos de redes neurais são capazes de alterar sua estrutura (Haykin, 2008).

2.3 Séries Temporais

Séries temporais podem ser definidas como um conjunto de dados que registram uma única variável ao longo do tempo de forma sequencial. A sua análise pode ser realizada por um conjunto de técnicas estatísticas e métodos matemáticos para realizar a compreensão do comportamento da variável ao longo do tempo, sendo aplicável na previsão de valores futuros em modelagem climática, decisões comerciais e financeiras (Lim and Zohren, 2021).

A sua utilização é válida principalmente pela sua capacidade de detectar tendências e sazonalidades, proporcionando previsões de valores futuros com cerca de acurácia dada evolução temporal histórica dos dados (Rajagukguk et al., 2020). No presente trabalho, duas variações de algoritmos de séries temporais serão utilizados, a primeira na Figura 1 calcula o valor da saída do instante com base nos valores anteriores da série em uma quantidade determinada, além de realizar os ajustes dos pesos sinápticos com base no erro da previsão, o retornando pela camada escondida. A segunda na Figura 2 é semelhante, porém também leva em consideração uma quantidade determinada das próprias saídas calculadas (Silva et al., 2010).




Figura 1. Topologia da TDNN (Silva et al., 2010).




Figura 2. Topologia da TDNNm (Silva et al., 2010).

3. MATERIAIS E MÉTODOS

3.1 Materiais

O desenvolvimento, treinamento e testes das redes neurais no trabalho serão realizadas por meio da linguagem de programação *Python* e com o uso do notebook Acer Nitro 5 N515-55-51D3.

3.2 Tratamento dos dados

As amostras históricas utilizadas foram aglutinadas a partir de dados públicos disponibilizados pelo Instituto Nacional de Meteorologia (INMET), entre os anos de 2010 e 2021 de mais de 600 estações no Brasil. Visando o foco nas condições climáticas próximas à Cornélio Procópio, no Paraná, 12 estações meteorológicas ao redor foram selecionadas para esse trabalho, como mostra a Figura 3. Visto que a previsão é horária, para a comparação entre ambos os modelos destacados na Introdução, foi realizado um tratamento dos dados de modo que a base final contém os dados médio horários por cada dia, dentro do período destacado.

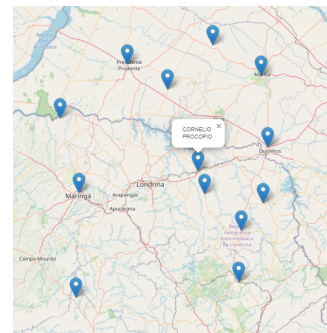


Figura 3. Estações selecionadas para o treinamento (Autoria própria, 2023).

Para o treinamento de ambas as redes neurais, foi selecionado um período de um mês (30 dias) no ano de 2016, durante a estação de inverno a qual é notoriamente reconhecida por contar baixos valores de irradiação em certos dias Salton et al. (2020), o que trás variação para o vetor de amostras disponibilizados na Figura 4.




Figura 4. Amostras de treinamento entre 01/06/2016 a 31/06/2016 (Autoria própria, 2023).

Para os testes de precisão de ambas as redes neurais, foi selecionado um período de 15 dias em sequência aos dias de treinamento, veja a Figura 5.




Figura 5. Amostras de teste entre 01/07/2016 a 15/07/2016 (Autoria própria, 2023).

3.3 Rede TDNN

As redes neurais artificiais do tipo TDNN com *momentum* é segmentada em três níveis de entradas, sendo eles: TDNN 1 com 1 dia de atraso (24 amostras); TDNN 2 com 3 dias de atraso (72 amostras); TDNN 3 com 7 dias de atraso (168 amostras). Os hiperparâmetros utilizados na rede neural TDNN implementada foi uma taxa de aprendizado de 0,02, fator de *momentum* de 0,5, precisão de $0,05 \times 10^{-6}$ entre o erro atual e o anterior e função de ativação logística (sigmóide).

3.4 Rede TDNNm

As redes neurais artificiais do tipo TDNN com realimentação de saídas é segmentada nos mesmos três níveis de entradas citados anteriormente, levando em consideração 1/4 de quantidade de saídas dada a quantidade de entradas. Os hiperparâmetros utilizado na rede neural TDNNm implementada são os mesmos utilizados anteriormente.

4. RESULTADOS E DISCUSSÕES

A seguir são demonstrados os treinos e testes de ambas as redes neurais propostas.

4.1 Resultados da Rede TDNN

A Tabela 1 a seguir mostra os resultados dos treinamentos por meio do erro quadrático médio (MSE) e número de épocas necessárias para alcançar um valor de precisão menor que o esperado.

Tabela 1. Resultados dos treinos da rede neural TDNN

| Treinamento | TDNN 1 | | TDNN 2 | | TDNN 3 | |
|-------------|---------------|--------|---------------|--------|---------------|--------|
| | MSE | Épocas | MSE | Épocas | MSE | Épocas |
| 1° (T1) | 8.2354^{-8} | 171 | 2.3943^{-7} | 165 | 5.3613^{-7} | 491 |
| 2° (T2) | 1.3811^{-7} | 119 | 2.2469^{-7} | 360 | 4.6007^{-7} | 462 |
| 3° (T3) | 8.2705^{-8} | 136 | 1.7345^{-7} | 218 | 3.1706^{-7} | 349 |

Pela dinâmica de erro e de épocas, as matrizes de pesos sinápticos selecionados para os testes são as seguintes:

TDNN 1 - T3; TDNN 2 - T2; TDNN 3 - T3. A Figura 6 a seguir mostra o comportamento visual dos cálculos de irradiação realizado pelos 3 treinamentos selecionados.




Figura 6. Treinos selecionados do TDNN (Autoria própria, 2023).

Para as 3 topologias propostas, com 24, 72 e 168 entradas atrasadas de valores do históricos, a Tabela 2 a seguir mostra o desempenho nos 15 dias selecionados para os testes, por meio do erro relativo médio (MRE) e da Variância entre as amostras alvo e as calculadas.

Tabela 2. Resultados dos testes da rede neural TDNN

| Teste | TDNN 1 | | TDNN 2 | | TDNN 3 | |
|-------|--------|-----------|--------|-----------|--------|-----------|
| | MRE | Variância | MRE | Variância | MRE | Variância |
| | 3.0163 | 0.0031 | 2.6436 | 0.0027 | 3.9493 | 0.0063 |

A análise dos resultados dos testes, mostram que a topologia mais precisa é a com 72 amostras atrasadas, ou seja, 3 dias, devido ao menor MRE e variância, possuindo, portanto, alta semelhança às variações diárias dos valores de irradiação solar, veja a Figura 7.




Figura 7. Testes da rede TDNN (Autoria própria, 2023).

4.2 Resultados da Rede TDNNm

A Tabela 3 a seguir mostra os resultados dos treinamentos por meio do erro quadrático médio (MSE) e número de épocas necessários para alcançar um valor de precisão menor que o esperado.

Tabela 3. Resultados dos treinos da rede neural TDNNm

| Treinamento | TDNNm 1 | | TDNNm 2 | | TDNNm 3 | |
|-------------|---------------|--------|---------------|--------|---------------|--------|
| | MSE | Épocas | MSE | Épocas | MSE | Épocas |
| 1° (T1) | 1.9322^{-7} | 144 | 1.9093^{-7} | 100 | 3.4558^{-7} | 226 |
| 2° (T2) | 7.4747^{-8} | 142 | 2.5878^{-7} | 107 | 1.9639^{-7} | 182 |
| 3° (T3) | 1.8581^{-7} | 234 | 1.7677^{-7} | 253 | 2.9479^{-7} | 363 |

Pela dinâmica de erro e de épocas, as matrizes de pesos sinápticos selecionados para os testes são as seguintes: TDNNm 1 - T2; TDNN 2 - T3; TDNN 3 - T2. A Figura 8 a seguir mostra o comportamento visual dos cálculos de irradiação realizado pelos 3 treinamentos selecionados.




Figura 8. Treinos selecionados do TDNNm (Autoria própria, 2023).

Para as 3 topologias propostas, com 24, 72 e 168 entradas atrasadas de valores do históricos e saídas realimentadas, a Tabela 4 a seguir mostra o desempenho nos 15 dias selecionados para os testes, por meio do MRE e da Variância entre as amostras alvo e as calculadas.

Tabela 4. Resultados dos testes da rede neural TDNNm

| Teste | TDNNm 1 | | TDNNm 2 | | TDNNm 3 | |
|-------|---------|-----------|---------|-----------|---------|-----------|
| | MRE | Variância | MRE | Variância | MRE | Variância |
| | 2.4899 | 0.0019 | 2.5725 | 0.0026 | 3.7867 | 0.0071 |

A análise dos resultados dos testes, mostram que a topologia mais precisa é a com 24 amostras atrasadas, ou seja, 1 dia, devido ao menor erro relativo médio (MRE) e variância, possuindo, portanto, alta semelhança às variações diárias dos valores de irradiação solar, veja a Figura 9.




Figura 9. Testes da rede TDNNm (Autoria própria, 2023).

4.3 Discussão dos resultados

Dados as topologias mais precisas de ambos os tipos de redes neurais artificiais, com, respectivamente 72 amostras atrasadas para a TDNN e 24 amostras e 6 saídas para a TDNNm, tem-se a comparação do desempenho do erro quadrático médio e erro relativo médio, além da quantidade de épocas e variância entre os valores de teste e os previstos na Tabela 5, e de forma complementar a dinâmica gráfica dos valores na Figura 10.

Tabela 5. Comparação de desempenho entre as redes neurais TDNN e TDNNm

| Métricas | TDNN 2 - T2 | TDNNm 1 - T2 |
|-----------|---------------|---------------|
| MSE | 2.2469^{-7} | 7.4747^{-8} |
| Épocas | 360 | 142 |
| MRE | 2.6436 | 2.4899 |
| Variância | 0.0027 | 0.0019 |




Figura 10. Comparação entre as redes neurais TDNN e TDNNm (Autoria própria, 2023).

A análise e comparação mostra que o modelo de rede neural MLP, com topologia *Nonlinear Auto-Regressive with exogenous inputs* (NARX), referida como TDNNm dada sua memória dos dados previstos, é mais precisa em ambas as métricas de erro, com uma menor variância e menos da metade de épocas necessárias para o treinamento alcançar o erro estabelecido por meio dos ajustes dos pesos sinápticos.

5. CONCLUSÃO

O presente trabalho trata da temática de transição energética para a geração com fontes renováveis em exponencial crescimento no presente século. Portanto, a capacidade de realizar a previsão de valores futuros da grandeza física irradiação solar é de enorme importância na implementação e eficiência de projetos de energia fotovoltaicas. Nesse cenário, por meio do embasamento via referencial teórico e implementação de rotina de treinamentos, as redes neurais artificiais propostas para a previsão de séries temporais se mostrou eficiente, em destaque para a qual utiliza, além dos valores históricos, os próprios valores previstos anteriormente, reduzindo os erros quadrático médio nos treinos e relativo médio nos testes, além de baixa variância com os valores futuros. Portanto, o objetivo de realizar o desenvolvimento de algoritmos de séries temporais e realizar a comparação entre as topologias foi cumprido, gerando um modelo preciso e robusto as variações da irradiação solar ao longo dos dias e semanas.

REFERÊNCIAS

- Barbieri, G.M.L., Costa, A.B.F.d., Oliveira, C., D'Ávila, V., and Jusevicius, M. (2017). Atlas Solarimétrico do Estado do Paraná. URL <https://solar.copel.com/solar/atlas-solarimetrico-copel.pdf>.
- Frei, C. and Kim, Y.D. (2019). World Energy Scenarios 2019. Technical report, World Energy Council, London, United Kingdom. URL <https://www.worldenergy.org>.
- Haykin, S. (2008). *Neural networks and learning machines*. Pearson, New Jersey, 3rd edition.
- Institute, E. (2023). Statistical Review of World Energy 2023. Technical Report 72. URL <https://www.energyinst.org/statistical-review/resources-and-data-downloads>.
- Lim, B. and Zohren, S. (2021). Time-series forecasting with deep learning: a survey. *Philosophical Transactions of the Royal Society A: Mathematical, Physical and Engineering Sciences*, 379(2194), 20200209. doi:10.1098/rsta.2020.0209. URL <https://royalsocietypublishing.org/doi/10.1098/rsta.2020.0209>.
- Mehdizadeh, S., Behmanesh, J., and Khalili, K. (2016). Comparison of artificial intelligence methods and empirical equations to estimate daily solar radiation. *The Journal of Atmospheric and Solar-Terrestrial Physics (JASTP)*, 146, 215–227. doi:https://doi.org/10.1016/j.jastp.2016.06.006. URL <https://www.sciencedirect.com/science/article/abs/pii/S1364682616301481>.
- Ortiz, M.S. (2014). Plataforma baseada em sensores sem fio para o monitoramento de parâmetros meteorológicos. URL <https://tede2.pucrs.br/tede2/handle/tede/3058>.

- Rajagukguk, R.A., Ramadhan, R.A.A., and Lee, H.J. (2020). A Review on Deep Learning Models for Forecasting Time Series Data of Solar Irradiance and Photovoltaic Power. *Energies*, 13(24), 6623. doi:10.3390/en13246623. URL <https://www.mdpi.com/1996-1073/13/24/6623>.
- Salton, F.G., Morais, H., and Lohmann, M. (2020). Períodos Secos no Estado do Paraná. *Revista Brasileira de Meteorologia*, 36(2), 295–303. doi:<https://doi.org/10.1590/0102-77863620163>. URL <https://www.scielo.br/j/rbmet/a/kHjyZLqDXPyK6gHvWsQsD4C/abstract/?lang=pt>.
- Silva, I.N.d., Spatti, D.H., and Flauzino, R.A. (2010). *Redes neurais artificiais para engenharia e ciências aplicadas: curso prático*. Editora, Artliber, São Paulo.
- Wu, J. and Chan, C.K. (2013). Prediction of hourly solar radiation with multi-model framework. *Energy Conversion and Management*, 76, 347–355. doi:10.1016/j.enconman.2013.07.067. URL <https://linkinghub.elsevier.com/retrieve/pii/S019689041300438X>.